

PUC RIO

Projeto MVP: Construção de um Pipeline de Dados na Nuvem

Pós-Graduação - Ciência de Dados e Analytics

Sprint: Engenharia de Dados

Ana Beatriz Cardoso da Silva

Contexto de Negócio

A obesidade é considerada um dos principais problemas de saúde pública da atualidade. Diversos estudos apontam que hábitos alimentares inadequados, sedentarismo e fatores hereditários estão associados ao aumento da incidência de sobrepeso e obesidade na população.

Além dos impactos diretos na qualidade de vida, a obesidade também está relacionada ao aumento do risco de doenças crônicas, como hipertensão arterial, diabetes tipo 2, doenças cardiovasculares e outras condições que geram custos significativos para sistemas de saúde públicos e privados.

Diante desse cenário, compreender quais hábitos alimentares e comportamentais estão mais associados aos diferentes níveis de obesidade torna-se uma questão relevante para apoiar ações de prevenção, conscientização e promoção da saúde.

Este projeto busca utilizar conceitos de Engenharia de Dados para construir um pipeline completo de coleta, armazenamento, transformação e análise de dados relacionados a hábitos alimentares e estilo de vida, permitindo investigar possíveis padrões associados à obesidade.

Justificativa da escolha do tema

A escolha do tema ocorreu a partir do interesse em compreender a relação entre alimentação, estilo de vida e saúde.

Inicialmente foi considerada a utilização de bases de dados relacionadas a pedidos de comida por aplicativos de delivery. Entretanto, durante a análise dessas bases foi observado que, apesar de apresentarem informações sobre consumo alimentar, normalmente não possuem indicadores de saúde dos usuários, impossibilitando responder perguntas mais relevantes relacionadas aos efeitos desses hábitos sobre a saúde.

Dessa forma, optou-se por utilizar um conjunto de dados que reúne simultaneamente informações sobre hábitos alimentares, atividade física e classificação de obesidade, permitindo realizar análises mais completas e alinhadas ao problema proposto.

Justificativa da escolha do Dataset

O dataset selecionado foi o **Obesity Dataset**, disponibilizado no Kaggle.

A escolha desta base ocorreu pelos seguintes motivos:

- Possui dados de hábitos alimentares dos indivíduos.
- Possui informações relacionadas à prática de atividade física.
- Contém características demográficas como idade e sexo.
- Possui indicadores relacionados ao estilo de vida.
- Apresenta uma classificação dos níveis de obesidade dos indivíduos.

Essas características permitem responder perguntas relacionadas à influência da alimentação e do comportamento sobre os níveis de obesidade, tornando a base adequada para a construção de um pipeline de dados completo.

Objetivo Geral

Construir um pipeline de dados em ambiente Cloud utilizando a plataforma Databricks para coletar, armazenar, transformar e analisar dados relacionados a hábitos alimentares, estilo de vida e níveis de obesidade, aplicando conceitos de Engenharia de Dados buscando identificar fatores associados ao aumento dos níveis de obesidade.

Objetivos Específicos

- Realizar a ingestão dos dados brutos na plataforma Databricks;
- Organizar os dados seguindo o conceito de arquitetura medalhão;
- Aplicar procedimentos de limpeza e padronização dos dados;
- Criar estruturas de dados adequadas para análise;
- Avaliar a qualidade dos dados recebidos;
- Produzir consultas e análises capazes de responder às perguntas de negócio definidas;
- Documentar todas as etapas do pipeline desenvolvido.

Pergunta principal

Quais hábitos alimentares e comportamentais apresentam maior associação com os diferentes níveis de obesidade observados nos indivíduos da base de dados?

Perguntas de Negócio

1. O consumo frequente de alimentos altamente calóricos (fast food) está associado a níveis mais elevados de obesidade?
2. A prática regular de atividade física reduz a incidência de obesidade?
3. A frequência de consumo de vegetais apresenta relação com níveis mais saudáveis de peso corporal?
4. O histórico familiar de sobrepeso ou obesidade exerce influência significativa sobre os níveis de obesidade dos indivíduos?
5. O histórico familiar de obesidade possui maior influência que os hábitos alimentares?
6. O meio de transporte utilizado apresenta alguma relação com os níveis de obesidade?
7. O tempo diário dedicado ao uso de tecnologia está associado a maiores níveis de obesidade?
8. Existe relação entre o consumo diário de água e a classificação de obesidade dos indivíduos?
9. Existe diferença significativa entre faixas etárias quanto aos níveis de obesidade?
10. Quais fatores apresentam maior associação com indivíduos classificados como obesos?

Origem dos Dados

Os dados foram obtidos por meio da plataforma Kaggle, repositório amplamente utilizado pela comunidade de Ciência de Dados e Engenharia de Dados para disponibilização de conjuntos de dados públicos utilizados em pesquisas e projetos analíticos.

O conjunto selecionado contém informações sobre características físicas, hábitos alimentares, prática de atividades físicas e classificação do nível de obesidade dos indivíduos.

Processo de Coleta dos Dados

Para a etapa de coleta, o dataset foi obtido a partir do Kaggle mediante download do arquivo original em formato CSV.

Posteriormente, o arquivo foi enviado para o ambiente Databricks Free Edition, onde passou a compor a camada inicial do pipeline de dados.

A estratégia de utilização de um arquivo CSV foi escolhida por simplificar o processo de ingestão e permitir maior foco nas etapas de modelagem, transformação e análise de dados propostas no MVP.

Justificativa da Plataforma Escolhida

A plataforma escolhida para o desenvolvimento do projeto foi o Databricks Free Edition.

A escolha ocorreu porque o próprio MVP recomenda sua utilização como ambiente principal de desenvolvimento, além de fornecer recursos integrados para ingestão, processamento, armazenamento e análise de dados em um único ambiente.

Outro fator relevante é a adoção nativa da arquitetura Lakehouse e do formato Delta Lake, permitindo organizar os dados em múltiplas camadas de processamento e simular cenários encontrados em ambientes profissionais de Engenharia de Dados.

Planejamento da modelagem de dados

Antes da implementação do pipeline, foi realizado um planejamento conceitual da arquitetura de dados. Como o conjunto de dados possui uma única entidade principal (indivíduos respondentes), optou-se por uma estrutura simplificada baseada na Arquitetura Medalhão, composta pelas camadas Bronze, Silver e Gold.

A camada Bronze será responsável pelo armazenamento dos dados brutos conforme recebidos da fonte original.

A camada Silver conterá os dados tratados, padronizados e enriquecidos com atributos derivados, permitindo análises consistentes.

A camada Gold concentrará tabelas analíticas desenvolvidas especificamente para responder às perguntas de negócio definidas no projeto.

Entendimento dos dados

O dataset selecionado possui informações demográficas, comportamentais, alimentares e de saúde relacionadas aos indivíduos analisados. O objetivo desta etapa é compreender as variáveis disponíveis e identificar quais delas poderão ser utilizadas para responder às perguntas de negócio propostas.

Dicionário de Dados

Coluna Original	Descrição
Sex	Sexo do indivíduo
Age	Idade
Height	Altura (cm)
Overweight_Obese_Family	Histórico familiar de sobrepeso ou obesidade
Consumption_of_Fast_Food	Consumo de fast food
Frequency_of_Consuming_Vegetables	Frequência de consumo de vegetais
Number_of_Main_Meals_Daily	Número de refeições principais diárias
Food_Intake_Between_Meals	Frequência de alimentação entre refeições
Smoking	Hábito de fumar
Liquid_Intake_Daily	Consumo diário de líquidos
Calculation_of_Calorie_Intake	Controle do consumo de calorias
Physical_Excercise	Frequência de atividade física
Schedule_Dedicated_to_Technology	Tempo dedicado ao uso de tecnologia
Type_of_Transportation_Used	Meio de transporte utilizado
Class	Classificação de peso corporal/obesidade

Relação entre perguntas de negócio e dados

Pergunta	Principais Colunas
Fast food está associado à obesidade?	Consumption_of_Fast_Food, Class
Exercício físico reduz obesidade?	Physical_Excercise, Class
Consumo de vegetais influencia o peso?	Frequency_of_Consuming_Vegetables, Class
Histórico familiar influencia a obesidade?	Overweight_Obese_Family, Class
Histórico familiar influencia mais que hábitos alimentares?	Overweight_Obese_Family, Consumption_of_Fast_Food, Frequency_of_Consuming_Vegetables, Class
Meio de transporte influencia obesidade?	Type_of_Transportation_Used, Class
Tempo de tecnologia influencia obesidade?	Schedule_Dedicated_to_Technology, Class
Consumo de água influencia obesidade?	Liquid_Intake_Daily, Class
Existem diferenças entre faixas etárias?	Age, Class
Quais fatores mais caracterizam pessoas obesas?	Todas as variáveis comportamentais + Class

Planejamento da arquitetura medalhão

Camada Bronze

Objetivo: armazenar os dados exatamente como recebidos do Kaggle, sem alterações.

Tabela: bronze_obesidade_raw

Colunas:

Sex

Age

Height

Overweight_Obese_Family

Consumption_of_Fast_Food

Frequency_of_Consuming_Vegetables

Number_of_Main_Meals_Daily

Food_Intake_Between_Meals

Smoking

Liquid_Intake_Daily

Calculation_of_Calorie_Intake

Physical_Excercise

Schedule_Dedicated_to_Technology

Type_of_Transportation_Used

Class

Camada Silver

Objetivo: Padronizar, limpar e enriquecer os dados.

Tabela: silver_obesidade_tratada

Transformações Previstas:

Padronização do dado:

1	2	1	2
Masculino	Feminino	Sim	Não

Criação de novas colunas:

faixa_etaria

18-25

26-35

36-45

46-54

nivel_atividade

Sedentário

Moderado

Ativo

nivel_uso_tecnologia

Baixo

Médio

Alto

Qualidade

- Verificação de valores nulos;
- Verificação de duplicidades;
- Padronização de categorias;
- Validação dos domínios das colunas.

Camada Gold

Cada tabela Gold terá uma pergunta de negócio associada.

Tabela Gold	Pergunta Respondida
gold_fastfood_obesidade	Fast food influencia obesidade?
gold_atividade_fisica	Exercício reduz obesidade?
gold_consumo_vegetais	Consumo de vegetais influencia obesidade?
gold_historico_familiar	Histórico familiar influencia obesidade?
gold_historico_vs_habitos	Histórico familiar influencia mais que alimentação?
gold_meio_transporte	Meio de transporte influencia obesidade?
gold_tempo_tecnologia	Tempo de tecnologia influencia obesidade?
gold_consumo_agua	Consumo de água influencia obesidade?
gold_faixa_etaria	Existem diferenças entre faixas etárias?
gold_perfil_obesidade	Quais fatores caracterizam indivíduos obesos?

Modelo conceitual das tabelas Gold

As tabelas da camada Gold foram planejadas com foco na resposta às perguntas de negócio definidas para o projeto. Cada tabela possui uma finalidade analítica específica e será alimentada a partir dos dados tratados na camada Silver. Essa abordagem garante que os indicadores produzidos estejam diretamente alinhados aos objetivos do projeto e permitam gerar informações relevantes para a análise dos fatores associados à obesidade.

gold_fastfood_obesidade

O consumo frequente de fast food está associado a níveis mais elevados de obesidade?

Coluna	Descrição
consumo_fastfood	Sim/Não
total_pessoas	Quantidade de indivíduos
qtd_obesos	Quantidade de obesos
percentual_obesidade	Percentual de obesidade

gold_atividade_fisica

A prática regular de atividade física reduz a incidência de obesidade?

Coluna	Descrição
nivel_atividade	Sedentário / Moderado / Ativo
total_pessoas	Total de indivíduos
qtd_obesos	Quantidade de obesos
percentual_obesidade	Percentual de obesidade

gold_consumo_vegetais

A frequência de consumo de vegetais apresenta relação com níveis mais saudáveis de peso corporal?

Coluna	Descrição
frequencia_vegetais	Raramente / Às vezes / Sempre
total_pessoas	Total de indivíduos
percentual_obesidade	Percentual de obesidade

gold_historico_familiar

O histórico familiar exerce influência significativa?

Coluna	Descrição
historico_familiar	Sim / Não
total_pessoas	Total de indivíduos
percentual_obesidade	Percentual de obesidade

gold_historico_vs_habitos

Pergunta:

O histórico familiar influencia mais que os hábitos alimentares?

Coluna	Descrição
historico_familiar	Sim/Não
consumo_fastfood	Sim/Não
consumo_vegetais	Frequência
percentual_obesidade	Percentual

gold_meio_transporte

O meio de transporte utilizado apresenta relação com os níveis de obesidade?

Coluna	Descrição
meio_transporte	Carro, moto, bicicleta, transporte público, caminhada
total_pessoas	Total de indivíduos
percentual_obesidade	Percentual

gold_tempo_tecnologia

O tempo diário dedicado ao uso de tecnologia está associado a maiores níveis de obesidade?

Coluna	Descrição
tempo_tecnologia	Baixo, Médio, Alto
total_pessoas	Total de indivíduos
percentual_obesidade	Percentual

gold_consumo_agua

Existe relação entre o consumo diário de água e a classificação de obesidade?

Coluna	Descrição
consumo_agua	Menos de 1 litro / Entre 1 e 2 litros / Mais de 2 litros.
total_pessoas	Total de indivíduos
percentual_obesidade	Percentual

gold_faixa_etaria

Existe diferença significativa entre faixas etárias quanto aos níveis de obesidade?

Coluna	Descrição
faixa_etaria	18-25, 26-35, 36-45, 46-54
total_pessoas	Total de indivíduos
percentual_obesidade	Percentual


gold_perfil_obesidade

Quais fatores apresentam maior associação com indivíduos classificados como obesos?

Coluna	Descrição
sexo	Masculino/Feminino
faixa_etaria	Faixa de idade
atividade_fisica	Nível de atividade
consumo_fastfood	Sim/Não
consumo_vegetais	Frequência
historico_familiar	Sim/Não
tempo_tecnologia	Nível
consumo_agua	Nível
classe_obesidade	Classificação
quantidade	Total de indivíduos

Fluxo da Arquitetura Medalhão

O pipeline seguirá a arquitetura medalhão composta pelas camadas Bronze, Silver e Gold. A camada Bronze armazenará os dados brutos obtidos do Kaggle. A camada Silver será responsável pela limpeza, padronização e enriquecimento dos dados. Por fim, a camada Gold conterá tabelas analíticas específicas para responder às perguntas de negócio definidas no projeto, permitindo a análise dos fatores associados à obesidade.



+-----+
| Exercício x Obesidade |
+-----+

+-----+
| gold_consumo_vegetais |
+-----+
| Vegetais x Obesidade |
+-----+

+-----+
| gold_historico_familiar |
+-----+
| Histórico x Obesidade |
+-----+

+-----+
| gold_historico_vs_habitos |
+-----+
| Genética x Alimentação |
+-----+

+-----+
| gold_meio_transporte |
+-----+
| Transporte x Obesidade |
+-----+

+-----+
| gold_tempo_tecnologia |
+-----+
| Tecnologia x Obesidade |
+-----+
+-----+
| gold_consumo_agua |
+-----+
| Água x Obesidade |
+-----+

```
+-----+
| gold_faixa_etaria |
+-----+
| Idade x Obesidade |
+-----+
```

```
+-----+
| gold_perfil_obesidade |
+-----+
| Perfil dos Indivíduos |
| Obesos |
+-----+
```

Estratégia de Qualidade dos Dados

Com o objetivo de garantir a confiabilidade das análises produzidas, serão aplicadas validações e procedimentos de qualidade durante a transição da camada Bronze para a camada Silver.

As principais verificações previstas são:

- Verificação da existência de valores nulos;
- Identificação de registros duplicados;
- Validação dos domínios das variáveis categóricas;
- Padronização dos valores categóricos para formato textual;
- Criação e validação das novas colunas.

Essas atividades têm como objetivo assegurar que os dados utilizados na camada Gold apresentem qualidade suficiente para responder às perguntas de negócio propostas.

Transformações Previstas na Camada Silver

Durante o processamento da camada Silver serão realizadas as seguintes transformações:

- Tradução dos códigos numéricos para valores descritivos.
- Padronização dos nomes das categorias.
- Criação da coluna **faixa_etaria**.
- Criação da coluna **nivel_atividade**.
- Criação da coluna **nivel_uso_tecnologia**.
- Padronização dos níveis de consumo de água.

- Padronização dos meios de transporte.
- Preparação dos dados para geração das tabelas analíticas da camada Gold.

Databricks

Ingestão dos Dados na Camada Bronze

A primeira etapa do pipeline consistiu na ingestão do arquivo CSV contendo o **Obesity Dataset**. O arquivo foi carregado no ambiente **Databricks Free Edition** utilizando a funcionalidade de upload de dados disponibilizada pela plataforma.

O processo foi realizado através da opção **New → Add or upload data → Create or modify a table**, permitindo importar o arquivo CSV e criar uma tabela gerenciada no ambiente Databricks.

Durante a ingestão, foi mantida a estrutura original do arquivo, sem aplicação de transformações ou alterações nos valores das variáveis. O cabeçalho do arquivo foi utilizado como nome das colunas e o delimitador correspondente ao formato CSV foi configurado para garantir a correta interpretação dos dados.

Após o carregamento, os dados foram armazenados na tabela:

bronze_obesidade_raw

A tabela representa a **camada Bronze** da arquitetura do pipeline e tem como finalidade preservar os dados brutos recebidos da fonte original. Dessa forma, nenhuma regra de negócio, limpeza ou padronização é aplicada nesta etapa.

Após a criação da tabela, foram realizadas consultas de validação para confirmar a existência dos registros e verificar a correta ingestão dos dados.


A tabela Bronze servirá como fonte para a próxima etapa do pipeline, correspondente à **camada Silver**, na qual serão realizadas as transformações, padronizações e criação dos atributos derivados definidos no planejamento do projeto.

Validação da Camada Bronze

Após a ingestão do arquivo CSV, foram realizadas consultas de validação para verificar a correta criação e carregamento da tabela **bronze_obesidade_raw**.

A primeira consulta permitiu visualizar uma amostra dos registros armazenados. Em seguida, foi realizada a contagem total de registros, resultando em **1.610 registros**. Por fim, foi verificada a estrutura da tabela, confirmando a presença das **15 colunas** originais do dataset.

Os testes confirmaram que os dados foram carregados corretamente na camada Bronze, sem aplicação de transformações nesta etapa. A validação foi feita no Notebook **01_validacao_bronze**.



4 minutes ago (2s) 2

```
SELECT COUNT(*) AS total_registros  
FROM bronze_obesidade_raw;
```

> [See performance \(1\)](#)

Table ▾ +

	¹ ₃ total_registros
1	1610

1 row | 2.189s runtime

i This result is stored as `_sqldf` and can be used in other [Python](#) and [SQL](#) cells.

The screenshot shows a SQL query execution interface. At the top, there's a status bar with a play button, a checkmark, the time '04:47 PM (1s)', and the number '3'. Below this, the SQL query is displayed: `%sql
SELECT *
FROM bronze_obesidade_raw
LIMIT 0;`. To the right of the query, there are icons for SQL, a trash can, a copy icon, a refresh icon, and a settings icon. Below the query, there's a link 'See performance (1)' and a checkmark with the text 'Checked for improvements'. The main area shows a table with columns: 'Sex', 'Age', 'Height', 'Overweight/Obese/Family', 'Consumption_of_Fast_Food', and 'Frequency_of_Consuming'. The table is empty, with the text 'No rows returned' in the center. At the bottom, there's a status bar showing '0 rows', '1.378s runtime', and 'Refreshed at 9/27/26, 4:47 PM (18m ago)'. A note at the bottom states: 'This result is stored as _sqlidf and can be used in other Python and SQL cells.'

Sex	Age	Height	Overweight/Obese/Family	Consumption_of_Fast_Food	Frequency_of_Consuming
No rows returned					

Processamento da Camada Silver

A camada Silver foi construída a partir da tabela `bronze_obesidade_raw`, mantendo os 1.610 registros originais e aplicando as transformações necessárias para disponibilizar os dados de forma padronizada e adequada às análises.

Foram realizadas a tradução dos códigos numéricos para valores descritivos, a padronização das categorias, a padronização dos níveis de consumo de líquidos e dos meios de transporte e a criação dos atributos derivados `faixa_etaria`, `nivel_atividade` e `nivel_uso_tecnologia`.

Também foram realizadas verificações de qualidade dos dados, incluindo a conferência da quantidade de registros, identificação de valores nulos e registros duplicados, validação dos domínios das variáveis categóricas e padronização das categorias. Os testes confirmaram a integridade e a consistência dos dados tratados.

A tabela resultante foi denominada `silver_obesidade_tratada` e será utilizada como fonte para a construção das tabelas analíticas da camada Gold. Certas considerações foram feitas no Notebook **02_silver_obesidade**.

SQL Editor 01_validacao_bronze 02_silver_obesidade x +

File Edit View Run Help Python Full Last edit was 6 minutes ago Run all Serverless Schedule Comments

05:27 PM (9s) 13 SQL

```
CREATE OR REPLACE TABLE silver_obesidade_tratada AS

SELECT
  CASE
    WHEN Sex = 1 THEN 'Masculino'
    WHEN Sex = 2 THEN 'Feminino'
  END AS sexo,

  Age AS idade,

  Height AS altura_cm,

  CASE
    WHEN Overweight_Obese_Family = 1 THEN 'Sim'
    WHEN Overweight_Obese_Family = 2 THEN 'Não'
  END AS historico_familiar,

  CASE
    WHEN Consumption_of_Fast_Food = 1 THEN 'Sim'
    WHEN Consumption_of_Fast_Food = 2 THEN 'Não'
  END AS consumo_fastfood,

  CASE
```

SQL Editor 01_validacao_bronze 02_silver_obesidade x +

File Edit View Run Help Python Full Last edit was 7 minutes ago

05:27 PM (9s) 13

```
CASE
  WHEN Frequency_of_Consuming_Vegetables = 1 THEN 'Raramente'
  WHEN Frequency_of_Consuming_Vegetables = 2 THEN 'Às vezes'
  WHEN Frequency_of_Consuming_Vegetables = 3 THEN 'Sempre'
END AS frequencia_vegetais,

CASE
  WHEN Number_of_Main_Meals_Daily = 1 THEN '1-2'
  WHEN Number_of_Main_Meals_Daily = 2 THEN '3'
  WHEN Number_of_Main_Meals_Daily = 3 THEN '3+'
END AS refeicoes_principais_dia,

CASE
  WHEN Food_Intake_Between_Meals = 1 THEN 'Raramente'
  WHEN Food_Intake_Between_Meals = 2 THEN 'Às vezes'
  WHEN Food_Intake_Between_Meals = 3 THEN 'Geralmente'
  WHEN Food_Intake_Between_Meals = 4 THEN 'Sempre'
END AS alimentacao_entre_refeicoes,

CASE
  WHEN Smoking = 1 THEN 'Sim'
  WHEN Smoking = 2 THEN 'Não'
END AS fumante,

CASE
  WHEN Liquid_Intake_Daily = 1 THEN 'Menos de 1 litro'
```

SQL Editor 01_validacao_bronze 02_silver_obesidade

File Edit View Run Help Python Full Last edit was 7 minutes ago

05:27 PM (9s) 13

```
WHEN Liquid_Intake_Daily = 1 THEN 'Menos de 1 litro'
WHEN Liquid_Intake_Daily = 2 THEN 'Entre 1 e 2 litros'
WHEN Liquid_Intake_Daily = 3 THEN 'Mais de 2 litros'
END AS consumo_liquidos,

CASE
  WHEN Calculation_of_Calorie_Intake = 1 THEN 'Sim'
  WHEN Calculation_of_Calorie_Intake = 2 THEN 'Não'
END AS controle_calorias,

CASE
  WHEN Physical_Exercise = 1 THEN 'Sem atividade'
  WHEN Physical_Exercise = 2 THEN '1-2 dias'
  WHEN Physical_Exercise = 3 THEN '3-4 dias'
  WHEN Physical_Exercise = 4 THEN '5-6 dias'
  WHEN Physical_Exercise = 5 THEN '6+ dias'
END AS atividade_fisica,

CASE
  WHEN Schedule_Dedicated_to_Technology = 1 THEN '0-2 horas'
  WHEN Schedule_Dedicated_to_Technology = 2 THEN '3-5 horas'
  WHEN Schedule_Dedicated_to_Technology = 3 THEN 'Mais de 5 horas'
END AS uso_tecnologia,

CASE
  WHEN Type_of_Transportation_Used = 1 THEN 'Automóvel'
  WHEN Type_of_Transportation_Used = 2 THEN 'Motocicleta'
```

SQL Editor 01_validacao_bronze 02_silver_obesidade

File Edit View Run Help Python Full Last edit was 8 minutes ago

05:27 PM (9s) 13

```
WHEN Type_of_Transportation_Used = 4 THEN 'Transporte público'
WHEN Type_of_Transportation_Used = 5 THEN 'Caminhada'
END AS meio_transporte,

CASE
  WHEN Class = 1 THEN 'Abaixo do peso'
  WHEN Class = 2 THEN 'Normal'
  WHEN Class = 3 THEN 'Sobrepeso'
  WHEN Class = 4 THEN 'Obesidade'
END AS classe_obesidade,

CASE
  WHEN Age BETWEEN 18 AND 25 THEN '18-25'
  WHEN Age BETWEEN 26 AND 35 THEN '26-35'
  WHEN Age BETWEEN 36 AND 45 THEN '36-45'
  WHEN Age BETWEEN 46 AND 54 THEN '46-54'
  ELSE 'Fora do intervalo'
END AS faixa_etaria,

CASE
  WHEN Physical_Exercise = 1 THEN 'Sedentário'
  WHEN Physical_Exercise IN (2, 3) THEN 'Moderado'
  WHEN Physical_Exercise IN (4, 5) THEN 'Ativo'
  ELSE 'Não classificado'
END AS nivel_atividade,

CASE
```

The screenshot shows a SQL Editor with two tabs: '01_validacao_bronze' and '02_silver_obesidade'. The top query is a CREATE OR REPLACE statement for a table named 'nivel_atividade' and 'nivel_uso_tecnologia'. The bottom query is a SELECT statement showing the first 10 rows of the 'silver_obesidade_tratada' table.

Query 1 (02_silver_obesidade):

```

WHEN Physical_Exercise IN (4, 5) THEN 'Ativo'
ELSE 'Não classificado'
END AS nivel_atividade,

CASE
  WHEN Schedule_Dedicated_to_Technology = 1 THEN 'Baixo'
  WHEN Schedule_Dedicated_to_Technology = 2 THEN 'Médio'
  WHEN Schedule_Dedicated_to_Technology = 3 THEN 'Alto'
  ELSE 'Não classificado'
END AS nivel_uso_tecnologia

FROM bronze_obesidade_raw;

```

Query 2 (02_silver_obesidade):

```

%sql
SELECT *
FROM silver_obesidade_tratada
LIMIT 10;

```

Table View (silver_obesidade_tratada):

	sexo	idade	altura_cm	historico_familiar	consumo_fastfood	frequencia_vegetais	refeicoes_principais_dia
1	Feminino	18	155	Não	Não	Sempre	1-2
2	Feminino	18	158	Não	Não	Sempre	1-2
3	Feminino	18	159	Não	Não	Às vezes	1-2
4	Feminino	18	162	Não	Não	Às vezes	3
5	Feminino	18	165	Não	Sim	Às vezes	1-2
6	Feminino	18	176	Sim	Sim	Raramente	1-2
7	Feminino	19	152	Não	Não	Sempre	1-2
8	Feminino	19	158	Não	Não	Sempre	3
9	Feminino	19	159	Não	Não	Às vezes	3
10	Feminino	19	160	Não	Não	Sempre	1-2

Construção da Camada Gold

A camada Gold foi desenvolvida a partir da tabela silver_obesidade_tratada, e no Notebook **03_gold_obesidade** com o objetivo de criar estruturas analíticas específicas para responder às perguntas de negócio definidas no projeto.

Foram construídas dez tabelas analíticas, cada uma direcionada a uma dimensão específica da análise:

- gold_fastfood_obesidade
- gold_atividade_fisica
- gold_consumo_vegetais
- gold_historico_familiar
- gold_historico_vs_habitos
- gold_meio_transporte
- gold_tempo_tecnologia
- gold_consumo_agua

- gold_faixa_etaria
- gold_perfil_obesidade

As tabelas foram criadas por meio de consultas SQL utilizando agregações como COUNT, SUM, CASE WHEN e cálculo de percentuais. Dessa forma, os dados tratados na camada Silver foram transformados em indicadores diretamente relacionados às perguntas de negócio.

Para a maioria das análises foi calculado o percentual de indivíduos classificados como obesos dentro de cada categoria analisada.

A tabela gold_perfil_obesidade foi construída de forma diferente das demais, agrupando exclusivamente os indivíduos classificados como obesos de acordo com características como sexo, faixa etária, atividade física, consumo de fast food, consumo de vegetais, histórico familiar, uso de tecnologia e consumo de água.

Após a criação das tabelas, foram executadas consultas de validação para verificar os resultados gerados. A tabela gold_perfil_obesidade, por exemplo, apresentou 179 combinações de perfis, totalizando 287 indivíduos classificados como obesos, valor consistente com os resultados obtidos nas demais tabelas analíticas.

Com a conclusão da camada Gold, o pipeline passou a disponibilizar dados preparados para a análise das perguntas de negócio e geração dos insights finais.

Alguns exemplos:

06:00 PM (2s) 6

```
%sql
SELECT *
FROM gold_consumo_vegetais;
```

> [See performance \(1\)](#)

	frequencia_vegetais	total_pessoas	percentual_obesidade
1	Raramente	400	46.00
2	Sempre	502	0.00
3	Às vezes	708	14.55

3 rows 2.125s runtime

06:01 PM (2s)

8

```
%sql
SELECT *
FROM gold_historico_familiar;
```

> [See performance \(1\)](#)

	A _C historico_familiar	1 ₃ total_pessoas	.00 percentual_obesidade
1	Não	1344	12.28
2	Sim	266	45.86

06:02 PM (2s)

10

```
%sql
SELECT *
FROM gold_historico_vs_habitos;
```

> [See performance \(1\)](#)

	A _C historico_familiar	A _C consumo_fastfood	A _C consumo_vegetais	.00 percentual_obesidade
1	Não	Não	Raramente	35.82
2	Não	Não	Sempre	0.00
3	Não	Não	Às vezes	6.92
4	Não	Sim	Raramente	42.86
5	Não	Sim	Sempre	0.00
6	Não	Sim	Às vezes	24.55
7	Sim	Não	Raramente	30.00
8	Sim	Não	Sempre	0.00
9	Sim	Não	Às vezes	56.00
10	Sim	Sim	Raramente	70.00
11	Sim	Sim	Sempre	0.00
12	Sim	Sim	Às vezes	42.86

▶

✓ 06:03 PM (2s)

12

```
%sql
SELECT *
FROM gold_meio_transporte;
```

> [See performance \(1\)](#)

Table ▾ +

	A ^B _C meio_transporte	1 ² ₃ total_pessoas	.00 percentual_obesidade
1	Automóvel	660	26.67
2	Bicicleta	116	1.72
3	Caminhada	138	15.94
4	Motocicleta	94	15.96
5	Transporte público	602	11.96

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60 61 62 63 64 65 66 67 68 69 70 71 72 73 74 75 76 77 78 79 80 81 82 83 84 85 86 87 88 89 90 91 92 93 94 95 96 97 98 99 100 101 102 103 104 105 106 107 108 109 110 111 112 113 114 115 116 117 118 119 120 121 122 123 124 125 126 127 128 129 130 131 132 133 134 135 136 137 138 139 140 141 142 143 144 145 146 147 148 149 150 151 152 153 154 155 156 157 158 159 160 161 162 163 164 165 166 167 168 169 170 171 172 173 174 175 176 177 178 179 180 181 182 183 184 185 186 187 188 189 190 191 192 193 194 195 196 197 198 199 200 201 202 203 204 205 206 207 208 209 210 211 212 213 214 215 216 217 218 219 220 221 222 223 224 225 226 227 228 229 230 231 232 233 234 235 236 237 238 239 240 241 242 243 244 245 246 247 248 249 250 251 252 253 254 255 256 257 258 259 260 261 262 263 264 265 266 267 268 269 270 271 272 273 274 275 276 277 278 279 280 281 282 283 284 285 286 287 288 289 290 291 292 293 294 295 296 297 298 299 300 301 302 303 304 305 306 307 308 309 310 311 312 313 314 315 316 317 318 319 320 321 322 323 324 325 326 327 328 329 330 331 332 333 334 335 336 337 338 339 340 341 342 343 344 345 346 347 348 349 350 351 352 353 354 355 356 357 358 359 360 361 362 363 364 365 366 367 368 369 370 371 372 373 374 375 376 377 378 379 380 381 382 383 384 385 386 387 388 389 390 391 392 393 394 395 396 397 398 399 400 401 402 403 404 405 406 407 408 409 410 411 412 413 414 415 416 417 418 419 420 421 422 423 424 425 426 427 428 429 430 431 432 433 434 435 436 437 438 439 440 441 442 443 444 445 446 447 448 449 450 451 452 453 454 455 456 457 458 459 460 461 462 463 464 465 466 467 468 469 470 471 472 473 474 475 476 477 478 479 480 481 482 483 484 485 486 487 488 489 490 491 492 493 494 495 496 497 498 499 500 501 502 503 504 505 506 507 508 509 510 511 512 513 514 515 516 517 518 519 520 521 522 523 524 525 526 527 528 529 530 531 532 533 534 535 536 537 538 539 540 541 542 543 544 545 546 547 548 549 550 551 552 553 554 555 556 557 558 559 560 561 562 563 564 565 566 567 568 569 570 571 572 573 574 575 576 577 578 579 580 581 582 583 584 585 586 587 588 589 590 591 592 593 594 595 596 597 598 599 600 601 602 603 604 605 606 607 608 609 610 611 612 613 614 615 616 617 618 619 620 621 622 623 624 625 626 627 628 629 630 631 632 633 634 635 636 637 638 639 640 641 642 643 644 645 646 647 648 649 650 651 652 653 654 655 656 657 658 659 660 661 662 663 664 665 666 667 668 669 670 671 672 673 674 675 676 677 678 679 680 681 682 683 684 685 686 687 688 689 690 691 692 693 694 695 696 697 698 699 700 701 702 703 704 705 706 707 708 709 710 711 712 713 714 715 716 717 718 719 720 721 722 723 724 725 726 727 728 729 730 731 732 733 734 735 736 737 738 739 740 741 742 743 744 745 746 747 748 749 750 751 752 753 754 755 756 757 758 759 760 761 762 763 764 765 766 767 768 769 770 771 772 773 774 775 776 777 778 779 780 781 782 783 784 785 786 787 788 789 790 791 792 793 794 795 796 797 798 799 800 801 802 803 804 805 806 807 808 809 810 811 812 813 814 815 816 817 818 819 820 821 822 823 824 825 826 827 828 829 830 831 832 833 834 835 836 837 838 839 840 841 842 843 844 845 846 847 848 849 850 851 852 853 854 855 856 857 858 859 860 861 862 863 864 865 866 867 868 869 870 871 872 873 874 875 876 877 878 879 880 881 882 883 884 885 886 887 888 889 890 891 892 893 894 895 896 897 898 899 900 901 902 903 904 905 906 907 908 909 910 911 912 913 914 915 916 917 918 919 920 921 922 923 924 925 926 927 928 929 930 931 932 933 934 935 936 937 938 939 940 941 942 943 944 945 946 947 948 949 950 951 952 953 954 955 956 957 958 959 960 961 962 963 964 965 966 967 968 969 970 971 972 973 974 975 976 977 978 979 980 981 982 983 984 985 986 987 988 989 990 991 992 993 994 995 996 997 998 999 1000 1001 1002 1003 1004 1005 1006 1007 1008 1009 1010 1011 1012 1013 1014 1015 1016 1017 1018 1019 1020 1021 1022 1023 1024 1025 1026 1027 1028 1029 1030 1031 1032 1033 1034 1035 1036 1037 1038 1039 1040 1041 1042 1043 1044 1045 1046 1047 1048 1049 1050 1051 1052 1053 1054 1055 1056 1057 1058 1059 1060 1061 1062 1063 1064 1065 1066 1067 1068 1069 1070 1071 1072 1073 1074 1075 1076 1077 1078 1079 1080 1081 1082 1083 1084 1085 1086 1087 1088 1089 1090 1091 1092 1093 1094 1095 1096 1097 1098 1099 1100 1101 1102 1103 1104 1105 1106 1107 1108 1109 1110 1111 1112 1113 1114 1115 1116 1117 1118 1119 1120 1121 1122 1123 1124 1125 1126 1127 1128 1129 1130 1131 1132 1133 1134 1135 1136 1137 1138 1139 1140 1141 1142 1143 1144 1145 1146 1147 1148 1149 1150 1151 1152 1153 1154 1155 1156 1157 1158 1159 1160 1161 1162 1163 1164 1165 1166 1167 1168 1169 1170 1171 1172 1173 1174 1175 1176 1177 1178 1179 1180 1181 1182 1183 1184 1185 1186 1187 1188 1189 1190 1191 1192 1193 1194 1195 1196 1197 1198 1199 1200 1201 1202 1203 1204 1205 1206 1207 1208 1209 1210 1211 1212 1213 1214 1215 1216 1217 1218 1219 1220 1221 1222 1223 1224 1225 1226 1227 1228 1229 1230 1231 1232 1233 1234 1235 1236 1237 1238 1239 1240 1241 1242 1243 1244 1245 1246 1247 1248 1249 1250 1251 1252 1253 1254 1255 1256 1257 1258 1259 1260 1261 1262 1263 1264 1265 1266 1267 1268 1269 1270 1271 1272 1273 1274 1275 1276 1277 1278 1279 1280 1281 1282 1283 1284 1285 1286 1287 1288 1289 1290 1291 1292 1293 1294 1295 1296 1297 1298 1299 1300 1301 1302 1303 1304 1305 1306 1307 1308 1309 1310 1311 1312 1313 1314 1315 1316 1317 1318 1319 1320 1321 1322 1323 1324 1325 1326 1327 1328 1329 1330 1331 1332 1333 1334 1335 1336 1337 1338 1339 1340 1341 1342 1343 1344 1345 1346 1347 1348 1349 1350 1351 1352 1353 1354 1355 1356 1357 1358 1359 1360 1361 1362 1363 1364 1365 1366 1367 1368 1369 1370 1371 1372 1373 1374 1375 1376 1377 1378 1379 1380 1381 1382 1383 1384 1385 1386 1387 1388 1389 1390 1391 1392 1393 1394 1395 1396 1397 1398 1399 1400 1401 1402 1403 1404 1405 1406 1407 1408 1409 1410 1411 1412 1413 1414 1415 1416 1417 1418 1419 1420 1421 1422 1423 1424 1425 1426 1427 1428 1429 1430 1431 1432 1433 1434 1435 1436 1437 1438 1439 1440 1441 1442 1443 1444 1445 1446 1447 1448 1449 1450 1451 1452 1453 1454 1455 1456 1457 1458 1459 1460 1461 1462 1463 1464 1465 1466 1467 1468 1469 1470 1471 1472 1473 1474 1475 1476 1477 1478 1479 1480 1481 1482 1483 1484 1485 1486 1487 1488 1489 1490 1491 1492 1493 1494 1495 1496 1497 1498 1499 1500 1501 1502 1503 1504 1505 1506 1507 1508 1509 1510 1511 1512 1513 1514 1515 1516 1517 1518 1519 1520 1521 1522 1523 1524 1525 1526 1527 1528 1529 1530 1531 1532 1533 1534 1535 1536 1537 1538 1539 1540 1541 1542 1543 1544 1545 1546 1547 1548 1549 1550 1551 1552 1553 1554 1555 1556 1557 1558 1559 1560 1561 1562 1563 1564 1565 1566 1567 1568 1569 1570 1571 1572 1573 1574 1575 1576 1577 1578 1579 1580 1581 1582 1583 1584 1585 1586 1587 1588 1589 1590 1591 1592 1593 1594 1595 1596 1597 1598 1599 1600 1601 1602 1603 1604 1605 1606 1607 1608 1609 1610 1611 1612 1613 1614 1615 1616 1617 1618 1619 1620 1621 1622 1623 1624 1625 1626 1627 1628 1629 1630 1631 1632 1633 1634 1635 1636 1637 1638 1639 1640 1641 1642 1643 1644 1645 1646 1647 1648 1649 1650 1651 1652 1653 1654 1655 1656 1657 1658 1659 1660 1661 1662 1663 1664 1665 1666 1667 1668 1669 1670 1671 1672 1673 1674 1675 1676 1677 1678 1679 1680 1681 1682 1683 1684 1685 1686 1687 1688 1689 1690 1691 1692 1693 1694 1695 1696 1697 1698 1699 1700 1701 1702 1703 1704 1705 1706 1707 1708 1709 1710 1711 1712 1713 1714 1715 1716 1717 1718 1719 1720 1721 1722 1723 1724 1725 1726 1727 1728 1729 1730 1731 1732 1733 1734 1735 1736 1737 1738 1739 1740 1741 1742 1743 1744 1745 1746 1747 1748 1749 1750 1751 1752 1753 1754 1755 1756 1757 1758 1759 1760 1761 1762 1763 1764 1765 1766 1767 1768 1769 1770 1771 1772 1773 1774 1775 1776 1777 1778 1779 1780 1781 1782 1783 1784 1785 1786 1787 1788 1789 1790 1791 1792 1793 1794 1795 1796 1797 1798 1799 1800 1801 1802 1803 1804 1805 1806 1807 1808 1809 1810 1811 1812 1813 1814 1815 1816 1817 1818 1819 1820 1821 1822 1823 1824 1825 1826 1827 1828 1829 1830 1831 1832 1833 1834 1835 1836 1837 1838 1839 1840 1841 1842 1843 1844 1845 1846 1847 1848 1849 1850 1851 1852 1853 1854 1855 1856 1857 1858 1859 1860 1861 1862 1863 1864 1865 1866 1867 1868 1869 1870 1871 1872 1873 1874 1875 1876 1877 1878 1879 1880 1881 1882 1883 1884 1885 1886 1887 1888 1889 1890 1891 1892 1893 1894 1895 1896 1897 1898 1899 1900 1901 1902 1903 1904 1905 1906 1907 1908 1909 1910 1911 1912 1913 1914 1915 1916 1917 1918 1919 1920 1921 1922 1923 1924 1925 1926 1927 1928 1929 1930 1931 1932 1933 1934 1935 1936 1937 1938 1939 1940 1941 1942 1943 1944 1945 1946 1947 1948 1949 1950 1951 1952 1953 1954 1955 1956 1957 1958 1959 1960 1961 1962 1963 1964 1965 1966 1967 1968 1969 1970 1971 1972 1973 1974 1975 1976 1977 1978 1979 1980 1981 1982 1983 1984 1985 1986 1987 1988 1989 1990 1991 1992 1993 1994 1995 1996 1997 1998 1999 2000 2001 2002 2003 2004 2005 2006 2007 2008 2009 2010 2011 2012 2013 2014 2015 2016 2017 2018 2019 2020 2021 2022 2023 2024 2025 2026 2027 2028 2029 2030 2031 2032 2033 2034 2035 2036 2037 2038 2039 2040 2041 2042 2043 2044 2045 2046 2047 2048 2049 2050 2051 2052 2053 2054 2055 2056 2057 2058 2059 2060 2061 2062 2063 2064 2065 2066 2067 2068 2069 2070 2071 2072 2073 2074 2075 2076 2077 2078 2079 2080 2081 2082 2083 2084 2085 2086 2087 2088 2089 2090 2091 2092 2093 2094 2095 2096 2097 2098 2099 2100 2101 2102 2103 2104 2105 2106 2107 2108 2109 2110 2111 2112 2113 2114 2115 2116 2117 2118 2119 2120 2121 2122 2123 2124 2125 2126 2127 2128 2129 2130 2131 2132 2133 2134 2135 2136 2137 2138 2139 2140 2141 2142 2143 2144 2145 2146 2147 2148 2149 2150 2151 2152 2153 2154 2155 2156 2157 2158 2159 2160 2161 2162 2163 2164 2165 2166 2167 2168 2169 2170 2171 2172 2173 2174 2175 2176 2177 2178 2179 2180 2181 2182 2183 2184 2185 2186 2187 2188 2189 2190 2191 2192 2193 2194 2195 2196 2197 2198 2199 2200 2201 2202 2203 2204 2205 2206 2207 2208 2209 2210 2211 2212 2213 2214 2215 2216 2217 2218 2219 2220 2221 2222 2223 2224 2225 2226 2227 2228 2229 2230 2231 2232 2233 2234 2235 2236 2237 2238 2239 2240 2241 2242 2243 2244 2245 2246 2247 2248 2249 2250 2251 2252 2253 2254 2255 2256 2257 2258 2259 2260 2261 2262 2263 2264 2265 2266 2267 2268 2269 2270 2271 2272 2273 2274 2275 2276 2277 2278 2279 2280 2281 2282 2283 2284 2285 2286 2287 2288 2289 2290 2291 2292 2293 2294 2295 2296 2297 2298 2299 2300 2301 2302 2303 2304 2305 2306 2307 2308 2309 2310 2311 2312 2313 2314 2315 2316 2317 2318 2319 2320 2321 2322 2323 2324 2325 2326 2327 2328 2329 2330 2331 2332 2333 2334 2335 2336 2337 2338 2339 2340 2341 2342 2343 2344 2345 2346 2347 2348 2349 2350 2351 2352 2353 2354 2355 2356 2357 2358 2359 2360 2361 2362 2363 2364 2365 2366 2367 2368 2369 2370 2371 2372 2373 2374 2375 2376 2377 2378 2379 2380 2381 2382 2383 2384 2385 2386 2387 2388 2389 2390 2391 2392 2393 2394 2395 2396 2397 2398 2399 2400 2401 2402 2403 2404 2405 2406 2407 2408 2409 2410 2411 2412 2413 2414 2415 2416 2417 2418 2419 2420 2421 2422 2423 2424 2425 2426 2427 2428 2429 2430 2431 2432 2433 2434 2435 2436 2437 2438 2439 2440 2441 2442 2443 2444 2445 2446 2447 2448 2449 2450 2451 2452 2453 2454 2455 2456 2457 2458 2459 2460 2461 2462 2463 2464 2465 2466 2467 2468 2469 2470 2471 2472 2473 2474 2475 2476 2477 2478 2479 2480 2481 2482 2483 2484 2485 2486 2487 2488 2489 2490 2491 2492 2493 2494 2495 2496 2497 2498 2499 2500 2501 2502 2503 2504 2505 2506 2507 2508 2509 2510 2511 2512 2513 2514 2515 2516 2517 2518 2519 2520 2521 2522 2523 2524 2525 2526 2527 2528 2529 2530 2531 2532 2533 2534 2535 2536 2537 2538 2539 2540 2541 2542 2543 2544 2545 2546 2547 2548 2549 2550 2551 2552 2553 2554 2555 2556 2557 2558 2559 2560 2561 2562 2563 2564 2565 2566 2567 2568 2569 2570 2571 2572 2573 2574 2575 2576 2577 2578 2579 2580 2581 2582 2583 2584 2585 2586 2587 2588 2589 2590 2591 2592 2593 2594 2595 2596 2597 2598 2599 2600 2601 2602 2603 2604 2605 2606 2607 2608 2609 2610 2611 2612 2613 2614 2615 2616 2617 2618 2619 2620 2621 2622 2623

▶ ✓ 06:05 PM (2s) 16			
<pre>%sql SELECT * FROM gold_consumo_agua;</pre> > See performance (1)			
Table ▼ +			
	A ^B _C consumo_agua	1 ² ₃ total_pessoas	.00 percentual_obesidade
1	Entre 1 e 2 litros	523	21.80
2	Mais de 2 litros	631	10.94
3	Menos de 1 litro	456	22.81

▶ ✓ 06:12 PM (2s) 18			
<pre>%sql SELECT * FROM gold_faixa_etaria;</pre> > See performance (1)			
Table ▼ +			
	A ^B _C faixa_etaria	1 ² ₃ total_pessoas	.00 percentual_obesidade
1	18-25	474	4.64
2	26-35	500	13.20
3	36-45	412	28.64
4	46-54	224	36.16

06:13 PM (2s) 20 SQL

```
%sql
SELECT *
FROM gold_perfil_obesidade;
```

> [See performance \(1\)](#) ✓ Checked for improvements

	sexo	faixa_etaria	atividade_fisica	consumo_fastfood	consumo_vegetais	historico_familiar	tempo_tecno
1	Masculino	36-45	Moderado	Sim	Raramente	Sim	Baixo
2	Masculino	36-45	Ativo	Sim	Às vezes	Não	Alto
3	Feminino	46-54	Moderado	Sim	Raramente	Não	Baixo
4	Masculino	26-35	Ativo	Sim	Raramente	Não	Médio
5	Masculino	36-45	Ativo	Sim	Raramente	Não	Médio
6	Feminino	36-45	Ativo	Sim	Raramente	Sim	Baixo
7	Masculino	36-45	Ativo	Sim	Às vezes	Sim	Médio
8	Masculino	46-54	Moderado	Não	Raramente	Não	Alto
9	Feminino	46-54	Moderado	Sim	Raramente	Não	Médio
10	Masculino	26-35	Ativo	Não	Às vezes	Não	Baixo
11	Feminino	46-54	Ativo	Sim	Raramente	Sim	Baixo
12	Masculino	46-54	Ativo	Não	Raramente	Não	Médio
13	Feminino	36-45	Ativo	Sim	Raramente	Sim	Alto
14	Masculino	46-54	Moderado	Não	Raramente	Não	Baixo

Conclusão - Análise das Perguntas

Análise 1 — Fast food e obesidade

Pergunta de negócio:

O consumo frequente de alimentos altamente calóricos (fast food) está associado a níveis mais elevados de obesidade?

Resultado obtido:

- Não consome fast food: **10,56%** de obesidade
- Consome fast food: **37,39%** de obesidade

Os resultados indicam uma associação entre o consumo de fast food e a obesidade na base analisada. Entre os indivíduos que declararam consumir fast food, **37,39%** foram classificados como obesos, enquanto entre aqueles que não consumiam esse tipo de alimento o percentual foi de **10,56%**.

Dessa forma, observa-se que a proporção de obesidade foi consideravelmente maior entre os indivíduos que consumiam fast food. Entretanto, esse resultado representa uma **associação observada no conjunto de dados** e não permite afirmar, isoladamente, que o consumo de fast food seja a causa da obesidade.

Análise 2 — Atividade física e obesidade

Pergunta de negócio:

A prática regular de atividade física reduz a incidência de obesidade?

Resultado obtido:

- Sedentário: **4,37%**
- Moderado: **13,64%**
- Ativo: **25,27%**

Os resultados obtidos nesta base apresentaram um comportamento diferente do esperado. O grupo classificado como "**Ativo**" apresentou o maior percentual de obesidade, com **25,27%**, seguido pelo grupo **Moderado**, com **13,64%**, e pelo grupo **Sedentário**, com **4,37%**.

Portanto, **neste conjunto de dados**, não foi observada uma redução da obesidade associada ao aumento do nível de atividade física. Pelo contrário, a proporção de indivíduos obesos foi maior entre os grupos com maior nível de atividade.

Esse resultado deve ser interpretado com cautela, pois representa apenas uma **associação observada na base analisada**. Ele não permite concluir que a prática de atividade física aumente a obesidade, já que outros fatores presentes no conjunto de dados podem estar relacionados a esse comportamento.

Análise 3 — Consumo de vegetais e obesidade

Pergunta de negócio:

A frequência de consumo de vegetais apresenta relação com níveis mais saudáveis de peso corporal?

Resultado obtido:

- Raramente: **46,00%**
- Às vezes: **14,55%**
- Sempre: **0,00%**

Os resultados indicam uma associação entre a frequência de consumo de vegetais e a obesidade na base analisada. Entre os indivíduos que declararam consumir vegetais

raramente, o percentual de obesidade foi de **46,00%**. Entre os que consumiam vegetais **às vezes**, esse percentual caiu para **14,55%**.

Já no grupo que declarou consumir vegetais **sempre**, não foram identificados indivíduos classificados como obesos, resultando em **0,00%** de obesidade.

Dessa forma, observa-se que, nesta base, uma maior frequência de consumo de vegetais esteve associada a menores percentuais de obesidade. Ainda assim, o resultado deve ser interpretado como uma associação observada no conjunto de dados, sem estabelecer uma relação causal.

Análise 4 — Histórico familiar e obesidade

Pergunta de negócio:

O histórico familiar de sobrepeso ou obesidade exerce influência significativa sobre os níveis de obesidade?

Resultado obtido:

- Sem histórico familiar: **12,28%**
- Com histórico familiar: **45,86%**

Os resultados indicam uma associação relevante entre histórico familiar e obesidade na base analisada. Entre os indivíduos que declararam possuir histórico familiar de sobrepeso ou obesidade, **45,86%** foram classificados como obesos.

Entre aqueles que não apresentavam histórico familiar, o percentual de obesidade foi de **12,28%**.

Dessa forma, observa-se que a obesidade foi proporcionalmente mais frequente entre os indivíduos com histórico familiar. Esse resultado sugere uma associação importante entre esse fator e a classificação de obesidade no conjunto de dados analisado.

Ainda assim, a análise representa uma associação observada na base e não permite afirmar, isoladamente, que o histórico familiar seja a causa da obesidade.

Análise 5 — Histórico familiar x hábitos alimentares

Pergunta de negócio:

O histórico familiar de obesidade possui maior influência que os hábitos alimentares?

Principais resultados observados:

- Sem histórico + sem fast food + vegetais raramente: **35,82%**
- Sem histórico + fast food + vegetais raramente: **42,86%**
- Com histórico + sem fast food + vegetais às vezes: **56,00%**
- Com histórico + fast food + vegetais raramente: **70,00%**
- Em todas as combinações com consumo de vegetais “Sempre”: **0,00%**

A análise conjunta entre histórico familiar, consumo de fast food e frequência de consumo de vegetais mostra que os maiores percentuais de obesidade ocorreram em combinações nas quais o indivíduo possuía **histórico familiar de sobrepeso ou obesidade**.

O maior percentual observado foi de **70,00%**, entre indivíduos com histórico familiar, que consumiam fast food e consumiam vegetais raramente. Também foi observado percentual de **56,00%** entre indivíduos com histórico familiar, sem consumo de fast food e com consumo de vegetais às vezes.

Esses resultados sugerem que o histórico familiar apresenta uma associação importante com a obesidade na base analisada, mas os hábitos alimentares também parecem modificar esse comportamento. Por isso, os dados não permitem afirmar de forma isolada que um fator tenha influência absoluta maior que o outro.

A análise indica que a combinação entre fatores familiares e hábitos alimentares pode estar associada a diferentes percentuais de obesidade.

Análise 6 — Meio de transporte e obesidade

Pergunta de negócio:

O meio de transporte utilizado apresenta alguma relação com os níveis de obesidade?

Resultado obtido:

- Automóvel: **26,67%**
- Motocicleta: **15,96%**

- Caminhada: **15,94%**
- Transporte público: **11,96%**
- Bicicleta: **1,72%**

Os resultados mostram diferenças no percentual de obesidade entre os diferentes meios de transporte utilizados pelos indivíduos da base.

O maior percentual foi observado entre os indivíduos que utilizavam **automóvel**, com **26,67%** de obesidade. Em seguida aparecem motocicleta, com **15,96%**, caminhada, com **15,94%**, e transporte público, com **11,96%**.

O menor percentual foi identificado entre os indivíduos que utilizavam **bicicleta**, com **1,72%**.

Dessa forma, observa-se uma associação entre o meio de transporte utilizado e a proporção de indivíduos obesos na base analisada. Entretanto, os resultados não permitem concluir que o meio de transporte seja responsável pela obesidade, apenas que existem diferenças entre os grupos observados.

Análise 7 — Tempo de tecnologia e obesidade

Pergunta de negócio:

O tempo diário dedicado ao uso de tecnologia está associado a maiores níveis de obesidade?

Resultado obtido:

- Baixo: **23,56%**
- Médio: **14,41%**
- Alto: **19,40%**

Os resultados não apresentaram um crescimento linear da obesidade conforme aumenta o tempo dedicado ao uso de tecnologia.

O maior percentual de obesidade foi observado no grupo com **baixo uso de tecnologia**, com **23,56%**. O grupo com uso **alto** apresentou **19,40%**, enquanto o grupo com uso **médio** apresentou o menor percentual, com **14,41%**.

Dessa forma, nesta base de dados, não foi identificada uma associação direta em que maior tempo de uso de tecnologia corresponda necessariamente a maiores níveis de obesidade.

Os resultados indicam que essa variável, isoladamente, não apresenta um padrão claro de associação com a obesidade, sendo necessário considerar outros fatores comportamentais e familiares presentes no conjunto de dados.

Análise 8 — Consumo de água e obesidade

Pergunta de negócio:

Existe relação entre o consumo diário de água e a classificação de obesidade?

Resultado obtido:

- Menos de 1 litro: **22,81%**
- Entre 1 e 2 litros: **21,80%**
- Mais de 2 litros: **10,94%**

Os resultados indicam uma associação entre o consumo diário de líquidos e a obesidade na base analisada.

O maior percentual de obesidade foi observado entre os indivíduos que consumiam **menos de 1 litro por dia**, com **22,81%**, seguido pelo grupo que consumia **entre 1 e 2 litros**, com **21,80%**.

Já entre os indivíduos que consumiam **mais de 2 litros por dia**, o percentual de obesidade foi menor, correspondendo a **10,94%**.

Dessa forma, observa-se que, nesta base, maiores níveis de consumo de líquidos estiveram associados a menores percentuais de obesidade. Entretanto, o resultado representa apenas uma associação observada nos dados e não permite estabelecer uma relação de causa e efeito.

Análise 9 — Faixa etária e obesidade

Pergunta de negócio:

Existe diferença significativa entre faixas etárias quanto aos níveis de obesidade?

Resultado obtido:

- 18–25 anos: **4,64%**
- 26–35 anos: **13,20%**

- 36–45 anos: **28,64%**
- 46–54 anos: **36,16%**

Os resultados mostram um aumento progressivo do percentual de obesidade conforme avançam as faixas etárias analisadas.

Entre os indivíduos de **18 a 25 anos**, o percentual de obesidade foi de **4,64%**. Na faixa de **26 a 35 anos**, esse percentual aumentou para **13,20%**. Entre os indivíduos de **36 a 45 anos**, foi observado percentual de **28,64%**, enquanto a faixa de **46 a 54 anos** apresentou o maior valor, com **36,16%**.

Dessa forma, nesta base de dados, observa-se uma associação entre maior faixa etária e maior percentual de obesidade.

Ainda assim, o resultado representa uma associação observada no conjunto de dados e não permite afirmar que a idade, isoladamente, seja a causa do aumento da obesidade.

Análise 10 — Perfil dos indivíduos obesos

Pergunta de negócio:

Quais fatores apresentam maior associação com indivíduos classificados como obesos?

Pela tabela `gold_perfil_obesidade`, os perfis mais frequentes aparecem com combinações de características como:

- faixas etárias de **36–45** e **46–54 anos**;
- níveis de atividade **Ativo** e **Moderado**;
- consumo de fast food frequentemente igual a **Sim**;
- consumo de vegetais muitas vezes em **Raramente**;
- presença de histórico familiar em várias das combinações;
- diferentes níveis de uso de tecnologia e consumo de água.

A análise do perfil dos indivíduos classificados como obesos mostrou que não existe uma única combinação de características predominante de forma absoluta. Os registros estão distribuídos entre diferentes combinações de sexo, faixa etária, nível de atividade física, consumo de fast food, consumo de vegetais, histórico familiar, uso de tecnologia e consumo de água.

Entre os perfis mais frequentes observados, destacam-se indivíduos das faixas etárias de **36 a 45 anos** e **46 a 54 anos**, além da presença recorrente de consumo de fast food e baixa frequência de consumo de vegetais.

Também foram observadas combinações com histórico familiar de sobrepeso ou obesidade entre os perfis com maior frequência.

Dessa forma, os resultados reforçam que a obesidade, nesta base de dados, está associada a uma combinação de fatores comportamentais, alimentares, familiares e demográficos, e não a uma única característica isolada.

A tabela `gold_perfil_obesidade` permitiu consolidar essas características em perfis analíticos, complementando as análises individuais realizadas nas demais tabelas Gold.

Síntese dos Principais Resultados

As análises realizadas a partir das tabelas da camada Gold permitiram identificar diferentes padrões relacionados à obesidade no conjunto de dados.

O consumo de fast food apresentou associação relevante com a obesidade, com percentual de **37,39%** entre consumidores, contra **10,56%** entre não consumidores.

O consumo de vegetais apresentou comportamento inverso: indivíduos que consumiam vegetais raramente apresentaram **46,00%** de obesidade, enquanto o grupo que declarou consumir sempre apresentou **0,00%**.

O histórico familiar também apresentou forte associação, com **45,86%** de obesidade entre indivíduos com histórico familiar, contra **12,28%** entre aqueles sem histórico.

Em relação à idade, observou-se crescimento progressivo do percentual de obesidade entre as faixas etárias, variando de **4,64%** entre 18 e 25 anos para **36,16%** entre 46 e 54 anos.

O consumo de mais de 2 litros de líquidos por dia esteve associado a menor percentual de obesidade, **10,94%**, quando comparado aos grupos de menor consumo.

Também foram identificadas diferenças entre os meios de transporte, com maior percentual de obesidade entre usuários de automóvel e menor entre usuários de **bicicleta**.

Por outro lado, variáveis como nível de atividade física e tempo dedicado à tecnologia apresentaram resultados menos intuitivos, não sendo observado um padrão simples de redução ou aumento da obesidade conforme essas variáveis.

No conjunto, os resultados mostram que a obesidade está associada a uma combinação de fatores alimentares, familiares, demográficos e comportamentais, reforçando a importância de analisar essas características de forma integrada.

Conclusão Geral do Projeto

O projeto atingiu o objetivo de construir um pipeline de dados completo em ambiente Cloud utilizando o Databricks, organizando os dados segundo a arquitetura medalhão composta pelas camadas Bronze, Silver e Gold.

Na camada Bronze, os dados foram armazenados em sua forma original. Na camada Silver, foram realizadas transformações, padronizações e criação de atributos derivados. Na camada Gold, foram desenvolvidas tabelas analíticas específicas para responder às perguntas de negócio definidas no início do projeto.

As análises realizadas permitiram identificar associações importantes entre obesidade e fatores como consumo de fast food, frequência de consumo de vegetais, histórico familiar, faixa etária, consumo de líquidos e meio de transporte.

Ao mesmo tempo, alguns resultados demonstraram que determinadas variáveis não apresentam comportamento linear ou facilmente explicável, como ocorreu com atividade física e uso de tecnologia. Isso reforça a necessidade de interpretar os resultados como associações existentes no conjunto de dados, sem estabelecer relações diretas de causalidade.

Dessa forma, o pipeline desenvolvido demonstrou como técnicas de Engenharia de Dados podem ser utilizadas para transformar dados brutos em informações estruturadas e relevantes para análise, possibilitando responder às perguntas de negócio propostas e gerar uma visão consolidada sobre os fatores associados à obesidade.

Autoavaliação

Considero que os objetivos definidos no início do trabalho foram atingidos de forma satisfatória. Foi possível construir um pipeline de dados no Databricks utilizando a arquitetura

medalhão, contemplando as camadas Bronze, Silver e Gold, além de realizar transformações, validações e análises voltadas às perguntas de negócio propostas.

Ao longo do desenvolvimento, consegui aplicar na prática conceitos de Engenharia de Dados, organização de dados, qualidade, SQL e análise de resultados. Também foi possível identificar limitações e interpretar os resultados com cautela, principalmente nos casos em que as associações observadas não apresentaram comportamento intuitivo.

De forma geral, avalio que o projeto cumpriu o objetivo proposto e contribuiu para consolidar os conhecimentos desenvolvidos durante a disciplina.